


דף נוסחאות ומדריך פתרון · מבוא ללמידת מכונה ומדעי הנתונים (12112123)

עמוד 1/4 · סטטיסטיקה תיאורית · התפלגות נורמלית — מבוסס על 11 מבחני 2023–2025 · כל החישובים אומתו בקוד

הכלל: מספר שמשמש כ"נתונים" (אי אפשר לחבר/למצע אותו בהיגיון) = קטגורי. ת"ז היא המלכודת האחרונה עליהם.

5 · התפלגות נורמלית (N(μ, σ)

$$Z = (x - \mu) / \sigma$$



שאל: טווח סימטרי — z לפי $Z(0.5 + 0.2)$ ימין: הטבלה תמיד מצטברת משמאל — ל"גדול מ" הופכים!

מתכון: $P(x < a)$

1. תקנון: $z = (a - \mu) / \sigma$

2. טבלה: $\Phi(z)$. עבור z שלילי: $\Phi(-z) = 1 - \Phi(z)$

3. "גדול מ": $P(x > a) = 1 - \Phi(z)$ — לא לשכוח להפוך!

4. טווח $[a, b]$: $\Phi(z_b) - \Phi(z_a)$. שני זנבות: מחברים אותם.

• דוגמה מלאה (חזרה ב-3 מבחנים): $N(70, 10)$, מתחת ל-50 או מעל 85: $\Phi(-2) + [1 - \Phi(1.5)] = 0.0228 + 0.0668 = 0.0896 \approx 9\%$

• טווח סימטרי של X: $z = Z(0.5 + X/2)$ — דוגמה 80%: $N(70, 10)$ נותן $Z(0.90) = 1.28$ [57.2, 82.8]

• טווח לא סימטרי: מפרקים לצדדים: $Y\%$ משמאל ל-μ — גבול שמאלי ב- $X = Y - 40$, $Y = 45$ — חלוקת $X = Y + 5$ מתוך 85% — $Z(0.5 + X)$ בדיוק 50% מצד אחד — הגבול ∞ (כל הזנב)!

• כלל אמפירי: $\pm 2\sigma \approx 95\%$, $\pm 3\sigma \approx 99.7\%$ (בסטנדרטית: [-1.96, 1.96])

• סטנדרטית: $\mu=0, \sigma=1$ — שונות = סטיית תקן = 1 (מתלכדות). התלכדות ממוצע=חציון=שכיח — בכל נורמלית.

דוגמאות תקנון מלאות (N(70,10))

שאלה	תקנון	טבלה	תשובה
$P(x < 50)$	$z = -2$	$\Phi(-2)$	0.0228
$P(x > 85)$	$z = 1.5$	$1 - \Phi(1.5)$	0.0668
$P(60 < x < 80)$	$z = \mp 1$	$\Phi(1) - \Phi(-1)$	0.6826
מרכזי 80%	$z = 1.28$	$70 \pm 1.28 \cdot 10$	[57.2, 82.8]

מלכודות נורמליות: ① "גדול מ" — $z-1$ ② Φ שלילי — $\Phi(-z) = 1 - \Phi(z)$ ③ בדיוק חצי מצד אחד — הגבול ∞. ④ התלכדות מדדים ≠ נורמליות.

Φ	0.85	0.875	0.90	0.925	0.94	0.95	0.975	0.985	0.995
Z	1.04	1.15	1.28	1.44	1.56	1.65	1.96	2.17	2.58
ביטוח	70%	75%	80%	85%	88%	90%	95%	97%	99%

CLT — התפלגות דגימה של ממוצעים

$$\bar{x} \sim N(\mu, \sigma/\sqrt{n}) \cdot SE = \sigma/\sqrt{n}$$

• התפלגות הממוצעים נורמלית לכל התפלגות מקור (גם אחידה/מוטת) — לכן מצורת הפעמון של הממוצעים אי אפשר להסיק כלום על המקור.

• עקומה צרה יותר ⇒ n גדול יותר. התוחלת נשמרת; סטיית התקן קטנה פי $1/\sqrt{n}$ (לא נשארת σ, ולא הופכת סטנדרטית).


1 · מדדי מרכז — ממוצע, חציון, שכיח

• ממוצע $= \sum x_i / n$ — רגיש מאוד לחריגים: ערך קיצוני בודד "מושך" אותו לכיוונו.

• חציון — הערך האמצעי אחרי מיון — עמיד לחריגים (כמעט לא זז). שכיח — הערך הנפוץ ביותר = פסגת ההיסטוגרמה.

• הדגמה: הנתונים [1, 2, 3, 4, 100] — ממוצע = 22, חציון = 3. חריג אחד הזיז את הממוצע פי 7 מהחציון! לכן בנתונים מוטים (שכר!) מדווחים חציון, וגם משלימים ערכים חסרים בחציון.

2 · הטיה (Skew) — הנושא שפותח כמעט כל מבחן



הזנב מושך את הממוצע לכיוונו; השכיח נשאר בפסגה; החציון תמיד באמצע בין שניהם

• מוטה חיובית (זנב ימני): שכיח > חציון > ממוצע. דוגמאות: שכר, מחירי דירות, זמני המתנה, משקלי ארגונים עם מיעוט כבדים.

• מוטה שלילית (זנב שמאלי): ממוצע > חציון > שכיח. דוגמאות: ציוני מבחן קל, גיל פרישה.

• סימטרית (וכל נורמלית): שלושתם מתלכדים במרכז.

• הכיוון ההפוך: נתון "ממוצע < חציון" — מוטה חיובית. "ממוצע = חציון" — עקבי עם סימטריה — אבל לא מוכיח נורמליות (גם אחידה ודו-פסגתית סימטרית מקיימות!).

• זיהוי מציור: מחפשים לאן משתרך הזנב — לשם ההטיה. פסגה משמאל + זנב ימני = חיובית (לא שלילית).

נוסחאות בסיס

• שונות: $\sigma^2 = \sum (x_i - \mu)^2 / n$ · סטיית תקן $= \sqrt{\text{שונות}}$. הדגמה: סטיות -2, 0, 2, 4, -4: $8\sqrt{5} = 2.83$

• מתאם פירסון: $r = \text{cov}(x, y) / (\sigma_x \cdot \sigma_y)$, טווח [-1, 1]. $r=1$ קו עולה מושלם. $r \approx 0$ אין קשר לינארי (ייתכן קשר אחר) · לא תלוי סקאלה.

• מתאם ≠ סיבתיות: לחפש משתנה שלישי: גלידה ↔ כרישים (קיץ), תחנות כיבוי ↔ שריפות (גודל עיר).

3 · היסטוגרמה מנורמלת (סכום גבהים = 1)

מתכון קריאה:

1. מספר פריטים בעמודה שלמה = גובה $N \times$. עמודה בגובה 0.15 עם $N=200$ — 30 פריטים.

2. שאלה על חצי עמודה (למשל "כמה מעל 172.5" כשהעמודה 170–175) — לא ניתן לחשב! נותנים רק חסמים: [סכום העמודות שמעבר, אותו סכום + העמודה החצויה].

3. חציון: סוכמים גבהים משמאל עד שמגיעים בדיוק ל-0.5 — שם החציון. אם 0.5 נופל בתוך עמודה — לא ניתן לקבוע מדויק.

4. ממוצע וסטיית תקן — לעולם לא ניתנים לחישוב מדויק מההיסטוגרמה (רק הערכה).

• צורת הפיזור מספרת על השונות: צורת U (מסה בקצוות) = שונות גבוהה — רווח סמך רחב; פעמון צר = שונות נמוכה — רווח צר. מדגם U אינו מנורמלי — אבל CI עדיין תקף (CLT).

4 · סוגי משתנים

סוג	מבחן	דוגמאות
קטגורי נומינלי	אין שום סדר	קבוצת דם, צבע, עיר, סוג חיה, ת"ז / מיקוד / מס' טלפון (!)
קטגורי אורדינלי	יש סדר, אין "מרחק"	השכלה, מידות S/M/L, רמת חריפות
כמותי	חשבון משמעותי	משקל, גובה, שעות שינה, שכר

• **map** עם כמה iterables — איבר מקביל מכל אחד; חיבור מחרוזות = שרשור ללא רווח.

• **hash table**: אינדקס = key % N ; התנגשויות נערמות ברשימת התא.

• **set על tuple מסיר כפילויות!** $\{1,2,3,4,5\} = \text{set}((1,3,4,5,5,2,1,1))$ — קריטי לפני jaccard.

Pandas — groupby

• **שתי עמודות:** `df.groupby(['a','b'])['c'].sum()` — **רשימה!** `['a']` ← שגיאה. איטרציה: `for key, g in df.groupby(...):` ; `g.shape` (שורות, עמודות). ברירת מחדל: ממיון לפי מפתח, והמפתח הופך ל-`index`.

• **as_index=False** (נבחן!): שומר את עמודת הקיבוץ כעמודה רגילה במקום index — נוח לפני `merge`: `df.groupby('class', as_index=False)['grade'].mean()`

• **apply עם lambda** (חוזר): יצירת עמודה מחושבת — `df['y'] = df['date'].apply(lambda d: int(d.split('/')[1]))` (חילוף חודש מ-DD/MM/YYYY).

Pandas — merge (תאר פלט בצורת dataframe!)

df1 (name, team)	df2 (team, est)	how = ...
Moshe · development Adam · research Emily · HR	development · 2008 research · 2013 finance · 2010	רק המשותפים: Adam, Moshe כל df1 + est=NaN עי: df1 כל: NaN(finance+) NaN(Emily+)

שאלת ההמשך הקבועה: מדדים על העמודה אחרי merge

`NaN`, 2013, 2008[:est עמודת 'left'how=
`count()` = 2 `sum()` = 4021.0
sum-י מדלנים על NaN — 13

פעולות קבוצה (set) — 6 הופעות

• `A.intersection(B)` = חיתוך · `A.union(B)` = איחוד · גודל החיתוך חלקי גודל האיחוד = `jaccard` על קבוצות.

• **(set) מסיר כפילויות תחילה!** $\{1,2,3,4,5\} = \text{set}((1,3,4,5,5,2,1,1))$ (5 איברים, לא 8).

מתכון merge:

- `inner` = חיתוך המפתחות (רק ערכים שקיימים בשני הצדדים).
- `left` = כל שורות השמאלי; חסרים בימני ← `NaN`.
- `outer` = איחוד; חסרים משני הצדדים ← `NaN`.
- מדד על העמודה: `count` **מדלג על NaN** (סופר רק ערכים), `sum` **מדלג על NaN**. `mean = sum/count` (על הקיימים).

דפוס הזהב — "מעל הממוצע בקבוצה"

```
g = df.groupby('dept', as_index=False)['sal'].mean()
g.rename(columns={'sal':'avg'}, inplace=True)
m = df.merge(g, on='dept')
print(m[m['sal'] > m['avg']])
```

`rename` ← `groupby` (שלא יתגש) ← `merge` (מצימד ממוצע לכל שורה) ← `סיון` בוליאני. חוזר עם עובדים ועם תלמידים/כיתות.

קודים מוכרים (הפלט מאומת בהרצה)

קוד	מה עושה	פלט
<code>set(...)+count>1</code>	ערכים חוזרים בלבד	[1,2,5,9]
ראשוניים 19..2 (מסכה)	סכום	77
פלינדרום (בניית הפוך)	756 / 757	True / False
<code>reversed + zip</code>	צופן מראה a ↔ z	a → z, b → y
LCM (while)	lcm(7,6)	42
<code>len(set(s))/len(s)</code>	גיוון לקסיקלי	16/19
<code>sorted(key=d.get)</code>	תו שכיח	'e'


מתכון "מה מבצעת התוכנית (במשפט אחד)":

- להריץ בראש על הקלט הנתון ולרשום את הפלט.
- לנסח את הכוונה, לא את השורות: "סוכמת את הראשוניים בין 2 ל-20", "בודקת האם המספר פלינדרום" — משפט אחד ברמת מהות.

6 · רווחי סמך (CI) לתוחלת

$$CI = \bar{x} \pm Z \cdot s / \sqrt{n} \quad L = 2 \cdot Z \cdot s / \sqrt{n}$$

(L = האורך הכולל של הרווח — פעמיים המרווח)



מתכון [left, right] של X% מהשטח" (חזר +8 פעמים!):

- סימטרי: $left = \mu - z \cdot \sigma$, $right = \mu + z \cdot \sigma$ ← $z = Z(0.5 + X/2)$. דוגמה: $N(70,10)$, 80%: $z=1.28$ [57.2, 82.8].
- לא-סימטרי (Y% משמאל, X% מימין): גבול שמאלי ב- $\mu - Z(0.5 - Y) \cdot \sigma$, ימני ב- בהתאמה $\mu + Z(0.5 + X) \cdot \sigma$. **צד עם 50%** ← ∞ .

מתכון חישוב CI (4 שלבים — להראות הכל!):

- אם נתונה **שונות** ← $s = \sqrt{\text{שונות}}$ (המלכודת מס' 1!)
 - Z לפי רמת ביטחון C: $Z((1+C)/2)$ — או ישר משורת "ביטחון" בטבלת עמוד 1. 99% ← 2.58 · 90% ← 1.65 · 85% ← 1.44
 - מרווח: $Z \cdot s / \sqrt{n}$
 - תשובה: [מרווח, מרווח] ($\bar{x} - \text{מרווח}$, $\bar{x} + \text{מרווח}$)
- מחושב:** שונות 2.5, $\bar{x}=500.8$, $n=100$, ביטחון 99%: $s=1.58$ ← מרווח $0.41 = 1.58/10 \cdot 2.58$ ← [500.39, 501.21]

מתכון גודל מדגם (אורך נדרש L):

- $\sqrt{n} = 2 \cdot Z \cdot s / L$ ← מעלים בריבוע
- מעגלים תמיד למעלה!** (519 אריות · 1153 ל-679 IQ צמיגים)

מתכון הפוך (נתון L, מחפשים שונות):

- $s = L \cdot \sqrt{n} / (2Z)$
- מבקשים שונות? **להעלות בריבוע**. (L=0.25, n=729, ביטחון 95% ← $s^2 = 0.25 \cdot 27 / 3.92 = 1.72$ ← 2.96)

מלכודות CI: ① שונות נתונה ← שורש לפני הצבה. ② "אורך/רוחב" = פעמיים המרווח. ③ התפלגות המקור אחידה/מוטת? **לא מפריע** — CLT מציל במדגם גדול. ④ תקן/דרישה מחוץ לרווח ← לא ניתן להצהיר עמידה בתקן.

פרשנות נכונה — נשאל שוב ושוב

- ✓ "בביטחון C, תוחלת האוכלוסייה נמצאת בטווח."
- ✗ "C אחוז מהפרטים בטווח." ✗ "פרט אקראי יפול בטווח בהסתברות C" — הרווח על הממוצע בלבד, והוא מצטמצם עם $\sqrt{n}$; פיזור הפרטים רחב בהרבה.

מה מצמצם את הרווח

n ↑ · רמת ביטחון ↓ (קטן Z) · שונות ↓ — וההפכים מרחיבים.

אל תבלבלו CI עם טווח נורמלי! CI לתוחלת = $\bar{x} \pm Z \cdot \sigma / \sqrt{n}$ (עם $\sqrt{n}$). טווח סימטרי של X% מהאוכלוסייה = $\mu \pm Z \cdot \sigma$ (בלי $\sqrt{n}$). שאלת [left,right] של 80% מהשטח" = הטווח, לא CI.

7 · פייתון — דפוסים ומלכודות

• **מפתח מילון חייב hashable**: `TypeError: tuple/str/int` ← `list` ← `tuple`.

• **tuple = immutable**: השמה `t[i]=x` ← `TypeError: list` — מותר.

• **פרמטרים לפונקציה:** `lst[i]= / lst.append(...)` משנים את המקור; `param = [...]` **מנתק** — המקור לא משתנה. מחרוזות `immutable` — לעולם לא משתנות דרך פרמטר.

• `s.replace("a", "X")` שקול ל- `s.join(s.split("a"))`

• `count(x)>1` חוזרים = `count(x)==1` יחידאיים — לקרוא את התנאי בעיון!

• **לזהות מה הקוד עושה — סימנים מנחים:** בניית מספר הפוך

(`r = r*10 + num%10`) ← פלינדרום/היפוך · `r%a==0 and r%b==0` עד `r==0` LCM:

• `d[c1]!=c2` עם `reversed` ← צופן/מיפוי · `set(list)` בתוך `comprehension` ←

הסרת כפילויות · `key % len` ← `hash table`.

• `[x if cond for x in L]` ← `SyntaxError` תקין: `[x for x in L if cond]`

8 · גרסיה לינארית

$$MSE = (1/n) \cdot \sum (y - \hat{y})^2 \cdot R^2 = 1 - SSE/SST$$


• R^2 = שונות מוסברת: $\frac{\sum (y - \bar{y})^2}{\sum (y - \bar{y})^2 + \sum (\hat{y} - \bar{y})^2} = 1 - \frac{\sum (\hat{y} - \bar{y})^2}{\sum (y - \bar{y})^2}$. ההגדרה נשענת על ניבוי רציף – לא ישימה ללוגיסטית (שם R^2 pseudo).

• **מקדמי רגרסיה פשוטה:** $b_1 = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sum (x - \bar{x})^2}$, $b_0 = \bar{y} - b_1 \cdot \bar{x}$ ← כשאין קשר (רעש): $b_1 = 0$ ו- $b_0 = \bar{y}$. **ממוצע y בדיוק.**

• **loss חלופי – הכלל:** מעניש כל שגיאה (בלי קיזוז) + קטן=טוב.

חלופה ל-MSE	תקין?	למה
$ \Delta $ (MAE)	✓	חיובי, מעניש כל שגיאה
Δ^4	✓	זוגי, רגיש לחריגים
Δ^3	✗	סימנים מתקזזים
Δ^2	✗	מתגמל שגיאות ענק

• **adjusted R^2 :** עולה תמיד עם עוד משתנה (גם חסר תועלת). $\text{adjusted } R^2$ משתנים מיותרים – פער גדל בין השניים = מודל עמוס. הסרת משתנה לא-מובהק ← $\text{adjusted } R^2$ עשוי לעלות.



להיות את הצורה לפני שבחרים מודל: U ← פולינומי/piece-wise (חיפוש נק' חיתוך שממזער MSE כולל של שני הקטעים) wise-piece: חיפוש חיתוך

מתכון טבלת OLS (חזרה ב-6 מבחנים):

- לכל משתנה להסתכל רק על $p < 0.05$: $|P| > 0.05$ מובהק – הסרתו תוריד R^2 . גדול = לא מובהק ← הסרה לא משפיעה; $\text{adjusted } R^2$ אף עשוי לעלות.
- R^2 לעולם לא עולה מהסרת משתנה.
- "למי ההשפעה הגדולה ביותר?" בלי scaling – לא ניתן לדעת! (מקדם תלוי סקאלה). אחרי scaling – כן, לפי |מקדם|.
- במטריצת מתאמים (פירסון) – כן משווים תמיד: |r| הגבוה מול y מנצח.
- CI של β_1 שכולל 0 (למשל [-3.11, 2.51]) ← אין עדות לקשר לינארי.

Multi-collinearity

- מתאם חזק בין משתנים בלתי תלויים (0.84: $x_2 - x_4$ · שטח → חדרים).
- **פוגע:** פרשנות מקדמים, סימן הפוך, מובהקות מזויפת (ק גדול למרות קשר אמיתי). **לא פוגע:** R^2 , חיזוי, test.
- **זיהוי קל** – מטריצת מתאמים. פתרון: להסיר את בעל המתאם הנמוך יותר עם y. scaling / dummy – לא פותרים.
- **דוגמה (2025א):** $Y = 3.36 + 0.2 \cdot \text{size} - 0.52 \cdot \text{bedrooms}$. הצבה (3, 1500): $3.36 + 300 - 1.56 = 301.8$. ✓ "כל חדר מוריד 0.52" X ← מקדם שלילי בגלל collinearity; המודל תקף לניבוי, R^2 גבוה.

מתכון "האם מתאים לרגרסיה לינארית?" (מטבלת נתונים):

- לצייר/לדמיין את הנקודות. מגמה מונוטונית (רק עולה או רק יורד) ← מתאים, $b_1 \neq 0$.
- צורת U / הפוך-U (יורד ואז עולה) ← לא מתאים – קו ישר יפספס. (חשבון חשמל מול טמפ' = U קלאסי).
- אומדן "על מפת": $\Delta y / \Delta x \approx b_1$ מהקצוות · $b_0 \approx y$ ההתחלתי פחות $b_1 \cdot x$.

scaling · קידוד · חסרים · לוגיסטית

- scaling ברגרסיה: לא משנה את טיב המודל; כן משנה מקדמים (גם scaling של y). לא הכרחי – בניגוד ל-KNN/KMeans/רשתות.
- נומינלי ← **dummy (one-hot)**. קידוד אזורים 1-5 ← כופה סדר ומרחק מלאכותיים X (כשל: מחיר גבוה באמצע הציר).
- ערכים חסרים בהתפלגות מוטת ← **חציון**.
- לוגיסטית: **sigmoid** $\sigma(z) = 1/(1+e^{-z})$ ← הסתברות; אימון **log loss** (עונש לוגריתמי על הסתברות שגויה – קטן כשצדקת בביטחון, מתפוצץ כשטעית בביטחון; לזהות במבחן!): $-\log(\hat{y}) - (1-y) \cdot \log(1-\hat{y})$ ← לא MSE.
- **למה לא R^2 רגיל בלוגיסטית?** R^2 מבוסס ריבועי טטיות של ניבוי רציף סביב ממוצע; כאן התוויות 0/1 והפלט הסתברות ← ההגדרה לא משקפת טיב סיווג. לכן $\text{pseudo-}R^2$ (McFadden), accuracy , confusion , precision/recall , ROC/AUC .
- **loss 0-1** "נובר" (סופר טעויות) אבל גם – נותן עונש זהה לטעות ב-0.49 ולטעות ב-0.01; $\log \text{loss}$ מבחין ולכן עדיף לאימון.

9 · סיווג והערכה

איזה מודל לפי צורת הפיזור? נתונים שזורים / טבעת / לא-לינארי ← **KNN, NNR**, **MLP** ✓. רגרסיה לוגיסטית ← גבול לינארי בלבד X. רגרסיה לינארית ← לא מסווג כלל X. KMeans ← לא מונחה, לא מנבא מחלקות X.

	pred A	pred B	pred C
act A	50	10	10
act B	20	50	20
act C	5	5	50

עמודה אדומה = $\text{precision}(A) = 50/70$
 שורה כחולה = $\text{recall}(A) = 50/70$
 $\text{accuracy} = \text{אלכסון/הכל} = 150/220$
 אותו תא אלכסון (50), מכנים שונים: precision = עמודה (מה שחזיתי) · recall = שורה (מה שאמיתי)

מתכון confusion:

- סה"כ דוגמאות = סכום כל התאים (220).
- $\text{precision}(X)$ = תא האלכסון של X חלקי **סכום עמודת** predicted X.
- $\text{recall}(X)$ = אותו תא חלקי **סכום שורת** actual X.
- "כמה דוגמאות B יש" = סכום שורת B (90).

- $P, R \in [0,1]$ · סכומם על מחלקות לא חייב $SR = 3 \cdot 1$ ייתכן (מסווג מושלם).
- $P+R \leq 2$ תמיד $P = 1$ לא גורר $R = 1$ (מסווג "שמרן").
- **accuracy לבדו לא מספיק:** מחלה של 1% – "תמיד בריא" נותן 99% ומחמיץ הכל ($\text{recall}=0$). שני מסווגים עם acc זהה ← נעדיף את המכסה את כל המחלקות.
- **F1-score** – הממוצע ההרמוני של precision ו- recall : $F1 = 2 \cdot P \cdot R / (P+R)$. מאזן בין השניים **במספר יחיד**; גבוה רק כששניהם גבוהים (אם אחד נמוך – $F1$ נמוך). שימושי כשהמחלקות לא מאוזנות, במקום להסתכל על accuracy מטעה. טווח [0,1], 1 = מושלם.
- **ROC/AUC:** TPR מול FPR על פני כל הספים. $\text{TPR} = TP/(TP+FN)$, $\text{recall} = \text{TPR}$, $\text{FPR} = FP/(FP+TN)$ (שיעור השליליים שסומנו בטעות). $AUC \approx 1$ דירוג מושלם · 0.5 ניחוש · **שינוי סף לא משנה AUC**.

דוגמה מלאה (מהמטריצה למעלה, סה"כ 220):


$$\text{precision}(A)=50/75 \cdot \text{recall}(A)=50/70 \cdot \text{precision}(C)=50/80 \cdot \text{recall}(C)=50/60$$

$$\text{accuracy}=150/220 \approx 0.68 \cdot \text{דוגמאות B בפועל} = \text{שורת B} = 90$$

שני מסווגים, אותו (5/10) accuracy: מסווג שלא חוזה C אף פעם ($\text{recall}(C)=0$) נחות מזה שמכסה את כל שלוש המחלקות – **נעדיף כיסוי מלא**. זו הסיבה ש- accuracy לבד מטעה.

10 · מרחקים ו-KNN

מנהטן	$\sum \Delta_i $	אוקלידי	$\sqrt{\sum \Delta_i^2}$
hamming	חלק המקומות השונים, מקום מול מקום — תמורה מלאה = 1.0 מחושב: $1/3 = ([1,1,0],[1,0,0])$		
jaccard (sets)	גודל החיתוך חלקי גודל האיחוד — זהים. מחושב: $0.5 = 4/8 = \{1,2,4,5,6,7,8\}$		
scipy.jaccard	אי-דמיון (0 = זהים): אי-הסכמה רק במקומות שלפחות אחד $\neq 0$. מחושב: $2/3 = ([1,1,1,0],[1,0,0,0])$		



שאלת פיזור — התבנית הקבועה:

K=1 טועה (שכן בודד מטעה)

K=3 מתקן (רוב מקומי)

"קיים R עם דיוק מלא" ← לרוב נכון

מתאים ל-KNN · ✓ KMeans · לינארית X

K=3: אדום 1, כחול 2 ← כחול המעגל = NNR ברדיוס 1

מתכון KNN מחושב (מנהטן, מ-2,2, K=3):

אל $W(1,1) \cdot (3,2) = 2$ · $1=W(2,5) \cdot 3=B(2,5) \cdot 3=B(4,1,5) \cdot 4=B(4,4) \cdot W=4$ ← שלושה קרובים: $W(1,1)W(2,5)B(3,2)$ ← רוב White. (עם K=1 היה יוצא אחרת — לשים לב ל-K!)

• K: גדול $\neq$ טוב! $|K|=|train|$ ← תמיד מחלקת הרוב. K קטן ← רגיש לרעש. בוחרים ב-K validation אי-זוגי מונע תיקו רק בבינארי (2-2-1 בחמש מחלקות!).

• scaling קריטי; אבל הכפלה אחידה של כל הצירים ← לא משנה כלום (סדר שכנים נשמר). StandardScaler שונה לכל-feature ← כן משנה. אחרי Standard מרחק לא חסום (מעל Nv אפשרי); אחרי MinMax חסום ב-Nv.


• עמיד לחריגים: ל-KNN אין שלב אימון ← CE loss לא רלוונטי (בחירת K כיוונון, לא אימון).

• NNR: רדיוס ענק ← מחלקת רוב (לא "יותר מדויק"). features זהים בין datasets ← "ייתכן $R1=R2$ ", "בוודאות" X. אחרי scaling הרדיוסים ישתנו.

• train/val/test: אימון / כיוונון (K, R) / הערכה סופית נקייה.

• CE (cross-entropy): מודד כמה ההסתברות שהמודל נתן למחלקה הנכונה רחוקה מ-1 — עונש על ביטחון שגוי. $CE = -\log_{10}(p)$, p = ההסתברות המחלקה האמיתית. $p < 0.1$ → $CE > 1$. דוגמה: אם A, פלט $[0.05, 0.90, 0.05]$ ← $\log(0.05) = -1.30$. לא חסום מלמעלה.

11 · רשתות נוירונים ו-Gradient Descent



α מתאים: יורדים למינימום

α גדול ($1 = \alpha^2$ על אף) זגזוג נצחי

מתכון צעד GD: ① נגזרת בנקודה: $f'(x)$ ② צעד $\alpha \cdot f'(x)$ ③ צעד $x \leftarrow x - \alpha \cdot f'(x)$.

מקסימום: מחליפים ל-+. מחושב: $x \leftarrow f=3$ ← $x=0$, $\alpha=0.1$, $y=x^2+3x$ → -0.3 . השלמת קוד: $slope=derivative(x)$ (לא הפונקציה!) ← $step=lr \cdot slope$ → $x=x-step$.

α	1 (על α^2 , מ-5)	0.5	0.1	0.1-	0	גדול מאוד
קורה	זגזוג ± 5 נצחי	0 בצעד אחד	ירידה הדרגתית	מטפס ומתרחק	לא זז	התברות

• תלולה (20×2) מסוכנת ממתונה (2×2) עם אותו scaling ← α "מעגל" את נוף ה-loss ועוזר לאימון.

• GD מול פתרון אנליטי: יתרון — עובד כשאין פתרון ל- $f'=0$; חיסרון — מקורב, עלול להיתקע בלוקאלי.

• Perceptron: רק הפרדה לינארית — נכשל ב-XOR; מדרגה לא גזירה. הפתרון: MLP + אקטיבציות לא-לינאריות.

sigmoid · softmax

$$\text{softmax}(z_i) = e^{z_i} / \sum e^{z_j} \cdot \sigma(z) = 1/(1+e^{-z})$$

• softmax: הופך וקטור ציונים גולמיים להתפלגות הסתברות על פני מחלקות — כולם ב-(0,1), סכום 1, תמיד חיובי (גם לקלט שלילי!), משמר סדר. מחושב:

$$e^{-1}=0.368, e^{1.5}=4.48, e^7=1096.6$$

$$[0.0003, 0.0041, 0.9956]$$

• חלופות פסולות: חלוקה בסכום (שלייליס!) · ריבועים (הורס סדר: 3- מנצח את 1) · argmax קשיח (לא גזיר).

• sigmoid: מכונן מספר יחיד לטווח (0,1) — הסתברות למחלקה חיובית. טווח (0,1) — לא $[-1,1]$ (זה tanh) בינארי בלבד; לא לרציף. softmax — כל מספר מחלקות (בבינארי שקולה ל-sigmoid).

• CNN — שיתוף משקלים: פרמטרים כמספר תאי הפילטר + זיהוי feature בכל מקום. LLM: טקסט רהוט ✓, אומן על שיחות ✓, רשת כמסווג token הבא ✓, אחזור עובדות מדויק X (היות!).

12 · אשכולות, PCA ו-Scaling

• K-Means: עזירה בהתכנסות (לא לפי גודל נתונים). רגיש לאתחול ← ריצות שונות = תוצאות שונות; טיפול: n_init (בוחרים inertia מערי) + KMeans++. קיים אתחול שמתכנס באיטרציה אחת. באגים בקוד: [0]shape · break · range(k) · previous=copy(current).

• בחירת K: לולאה + silhouette (מקסימום) או elbow על $\sum ||x-cl||^2$ (סכום ריבועי המרחקים מכל נקודה למרכז האשכול שלה — מודד כמה האשכולות "הדוקים") — יורד תמיד, מחפשים את ה"שבירה".

• rand index: זוגות מוסכמים / $n(n-1)/2$. שיטה: לספור את הלא-מוסכמים. $[A,A,B,B,B]$ מול $[0,0,1,1,2]$: רק (3,5), (4,5) → $0.8 = 8/10$.

• purity: $\sum$ (רוב בכל אשכול) $12/(3+4+2) = 0.75$. חסם 1; טריוויאלי ב-K=N.

• silhouette: $s=(b-a)/\max(a,b)$ a=מרחק ממוצע לאשכול שלי, b=לאשכול השכן הקרוב: $s \rightarrow 1$ = מופרד היטב, $s \rightarrow 0$ = על הגבול, ללא תיגום — הפרדה גיאומטרית. שתי חלוקות נכונות זהות-rand יכולות לקבל s שונה. precision/recall — לא לאשכולות!

• אלגוריתם סף-דמיון (תרגיל 4, נבחן פעמיים ב-2025): MS גבוה ← אשכולות קטנים ורבים; NUM=n ייתכן: $MS1>MS2$ ← בוודאות $NUM1>NUM2$ X (מגמה כן, ודאות לא). יתרונות מול KMeans: לא צריך K, סובלני לחריגים.

• DBSCAN: eps ← מיוזג, רעש! הכל רעש ← eps או min_samples; אשכול ענק ← ההפך, אין K.

• PCA: מתאם מושלם ← $PC1=100\%$, $PC2=0\%$. מתאם חזק ← כיוון הסכום מסביר את הרוב.

• StandardScaler: $\sigma/(x-\mu)$ ← ממוצע 0, $\sigma=1$, לא חסום; פר-עמודה ($axis=0$). מחושב: $[1,3,5,7,9]$ ← $[-1.41,-0.71,0,0.71,1.41]$ MinMax. $[0,1]$ ← $[-5,10,15,7]$ ← $[0, 0.75, 1, 0.6]$ Standard מעביר ל-[0,1]! X • מונחית = יש תוויות (מחירים, ספרות); לא מונחית = מבנה בלי תוויות (פילוח, קיבוץ). KMeans אינו מסווג!

סיכום: פונקציית אימון והערכה לכל מודל

מודל	אימון (loss)	scaling חשוב?	לא-לינארית?
רגרסיה לינארית	MSE	לא (רק לפרשנות)	לא
רגרסיה לוגיסטית	log loss	כן (ב-GD)	לא (גבול לינארי)
KNN / NNR	אין אימון!	כן (מרחקים)	כן ✓
רשת (MLP)	cross-entropy	כן	כן ✓
KMeans	inertia (לא מונחה)	כן	—

מלכודות-על — לבדוק לפני הגשה: ① שונות נתונה ← שורש. ② אורך CI = $2 \times$ מרווח; n מעוגל למעלה. ③ ת"ז/מיקוד = קטגורי. K ④ sigmoid $\in (0,1)$. אי-זוגי רק בבינארי. ⑤ "ייתכן" כמעט תמיד נכון, "בוודאות" כמעט תמיד לא. ⑦ "הכי משפיע" בלי scaling ← לא ניתן לדעת. ⑧ $P(x>a)$ — להפוך את ערך הטבלה. ⑨ KMeans אינו מסווג; ל-KNN אין אימון. ⑩ merge: count/sum מדלגים על R^2 . ⑪ NaN לא עולה בהסרה. ⑫ collinearity לא פוגע בחיזוי — רק בפרשנות.

מבנה המבחן (לפי 11 מועדים): 14- שאלות · שתיים וחצי · "מה יודפס + מה מבצעת (במשפט אחד)" · "נכון/לא נכון והסבירו" · "סמנו את כל הנכונות" · חישוב מלא עם דרך · שאלת פיזור · שאלת OLS. טכניקה: נכון/לא-נכון בלי נימוק = חצי נקודות; בחישובים להראות הצבה מלאה — נקודות חלקיות על דרך; "מה מבצעת" — משפט אחד ברמת כוונה.

כל החישובים אומתו בהרצת קוד · בהצלחה!