


דף נוסחאות ומדריך פתרון · מבוא ללמידת מכונה ומדעי הנתונים (12112123)

עמוד 1/4 · סטטיסטיקה תיאורית · התפלגות נורמלית — מבוסס על 11 מבחני 2023–2025 · כל החישובים אומתו בקוד


הכלל: מספר שמשמש כ"נתונים" (אי אפשר לחבר/למצע אותו בהיגיון) = קטגורי. ת"ז היא המלכודת האחרונה עליהם.

5 · התפלגות נורמלית (N(μ, σ)

$$Z = (x - \mu) / \sigma$$



הטבלה נותנת את השטח משמאל



שאלה: טווח סימטרי — z לפי $Z(0.5 + 0.5/2)$ ימין: הטבלה תמיד מצטברת משמאל — ל"גדול מ" הופכים!

מתכון: $P(x < a)$

1. תקנון: $z = (a - \mu) / \sigma$

2. טבלה: $\Phi(z)$. עבור z שלילי: $\Phi(-z) = 1 - \Phi(z)$

3. "גדול מ": $P(x > a) = 1 - \Phi(z)$ — לא לשכוח להפוך!

4. טווח $[a, b]$: $\Phi(z_b) - \Phi(z_a)$ · שני זנבות: מחברים אותם.

• דוגמה מלאה (חזרה ב-3 מבחנים): $N(70, 10)$, מתחת ל-50 או מעל 85: $\Phi(-2) + [1 - \Phi(1.5)] = 0.0228 + 0.0668 = 0.0896 \approx 9\%$

• טווח סימטרי של X: $z = Z(0.5 + X/2)$ · דוגמה 80%: $N(70, 10)$ נותן $Z(0.90) = 1.28$ [57.2, 82.8]

• טווח לא סימטרי: מפרקים לצדדים: $Y\%$ משמאל ל-μ — גבול שמאלי ב- $X = Y - 40$, $X = 45$ מתוך $X = Y + 5$ חלוקת 85% — $Z(0.5 + X)$ בדיוק 50% מצד אחד — הגבול ∞ (כל הזנב)!

• כלל אמפירי: $\pm 2\sigma \approx 95\%$, $\pm 3\sigma \approx 99.7\%$ (בסטנדרטית: [-1.96, 1.96])

• סטנדרטית: $\mu=0, \sigma=1$ — שונות = סטיית תקן = 1 (מתלכדות). התלכדות ממוצע=חציון=שכיח — בכל נורמלית.

דוגמאות תקנון מלאות (N(70,10))

שאלה	תקנון	טבלה	תשובה
$P(x < 50)$	$z = -2$	$\Phi(-2)$	0.0228
$P(x > 85)$	$z = 1.5$	$1 - \Phi(1.5)$	0.0668
$P(60 < x < 80)$	$z = \mp 1$	$\Phi(1) - \Phi(-1)$	0.6826
מרכזי 80%	$z = 1.28$	$70 \pm 1.28 \cdot 10$	[57.2, 82.8]

מלכודות נורמליות: ① "גדול מ" — $z = 1$ ② $\Phi(-z) = 1 - \Phi(z)$ ③ בדיוק חצי מצד אחד — הגבול ∞. ④ התלכדות מדדים ≠ נורמליות.

Φ	0.85	0.875	0.90	0.925	0.94	0.95	0.975	0.985	0.995
Z	1.04	1.15	1.28	1.44	1.56	1.65	1.96	2.17	2.58
ביטוח	70%	75%	80%	85%	88%	90%	95%	97%	99%

CLT — התפלגות דגימה של ממוצעים

$$\bar{x} \sim N(\mu, \sigma/\sqrt{n}) \cdot SE = \sigma/\sqrt{n}$$

• התפלגות הממוצעים נורמלית לכל התפלגות מקור (גם אחידה/מוטת) — לכן מצורת הפעמון של הממוצעים אי אפשר להסיק כלום על המקור.

• עקומה צרה יותר ⇒ n גדול יותר. התוחלת נשמרת; סטיית התקן קטנה פי $1/\sqrt{n}$ (לא נשארת σ, ולא הופכת סטנדרטית).


1 · מדדי מרכז — ממוצע, חציון, שכיח

• ממוצע $= \sum x_i / n$ — רגיש מאוד לחריגים: ערך קיצוני בודד "מושך" אותו לכיוונו.

• חציון — הערך האמצעי אחרי מיון — עמיד לחריגים (כמעט לא זז). שכיח — הערך הנפוץ ביותר = פסגת ההיסטוגרמה.

• הדגמה: הנתונים [1, 2, 3, 4, 100] — ממוצע = 22, חציון = 3. חריג אחד הזיז את הממוצע פי 7 מהחציון! לכן בנתונים מוטים (שכרי) מדווחים חציון, וגם משלימים ערכים חסרים בחציון.

2 · הטיה (Skew) — הנושא שפותח כמעט כל מבחן



הזנב מושך את הממוצע לכיוונו; השכיח נשאר בפסגה; החציון תמיד באמצע בין שניהם

• מוטה חיובית (זנב ימני): שכיח > חציון > ממוצע. דוגמאות: שכר, מחירי דירות, זמני המתנה, משקלי ארגונים עם מיעוט כבדים.

• מוטה שלילית (זנב שמאלי): ממוצע > חציון > שכיח. דוגמאות: ציוני מבחן קל, גיל פרישה.

• סימטרית (וכל נורמלית): שלושתם מתלכדים במרכז.

• הכיוון ההפוך: נתון "ממוצע < חציון" — מוטה חיובית. "ממוצע = חציון" — עקבי עם סימטריה — אבל לא מוכיח נורמליות (גם אחידה ודו-פסגתית סימטרית מקיימות!).

• זיהוי מצויור: מחפשים לאן משתרך הזנב — לשם ההטיה. פסגה משמאל + זנב ימני = חיובית (לא שלילית).

נוסחאות בסיס

• שונות: $\sigma^2 = \sum (x_i - \mu)^2 / n$ · סטיית תקן $= \sqrt{\text{שונות}}$. הדגמה: סטיות -2, 0, 2, 4, -4: $8\sqrt{5} = 2.83$

• מתאם פירסון: $r = \text{cov}(x, y) / (\sigma_x \cdot \sigma_y)$, טווח [-1, 1]. $r=1$ קו עולה מושלם. $r \approx 0$ אין קשר לינארי (ייתכן קשר אחר) · לא תלוי סקאלה.

• מתאם ≠ סיבתיות: לחפש משתנה שלישי: גלידה ↔ כרישים (קיץ), תחנות כיבוי ↔ שריפות (גודל עיר).

3 · היסטוגרמה מנורמלת (סכום גבהים = 1)

מתכון קריאה:

1. מספר פריטים בעמודה שלמה = גובה $N \times$. עמודה בגובה 0.15 עם $N=200$ — 30 פריטים.

2. שאלה על חצי עמודה (למשל "כמה מעל 172.5" כשהעמודה 170–175) — לא ניתן לחשב! נותנים רק חסמים: [סכום העמודות שמעבר, אותו סכום + העמודה החצויה].

3. חציון: סוכמים גבהים משמאל עד שמגיעים בדיוק ל-0.5 — שם החציון. אם 0.5 נופל בתוך עמודה — לא ניתן לקבוע מדויק.

4. ממוצע וסטיית תקן — לעולם לא ניתנים לחישוב מדויק מההיסטוגרמה (רק הערכה).

• צורת הפיזור מספרת על השונות: צורת U (מסה בקצוות) = שונות גבוהה — רווח סמך רחב; פעמון צר = שונות נמוכה — רווח צר. מדגם U אינו מנורמלי — אבל CI עדיין תקף (CLT).

4 · סוגי משתנים

סוג	מבחן	דוגמאות
קטגורי נומינלי	אין שום סדר	קבוצת דם, צבע, עיר, סוג חיה, ת"ז / מיקוד / מס' טלפון (!)
קטגורי אורדינלי	יש סדר, אין "מרחק"	השכלה, מידות S/M/L, רמת חריפות
כמותי	חשבון משמעותי	משקל, גובה, שעות שינה, שכר

• **map** עם כמה iterables — איבר מקביל מכל אחד; חיבור מחרוזות = שרשור ללא רווח.

• **hash table**: אינדקס = key % N ; התנגשויות נערמות ברשימת התא.

• **set על tuple מסיר כפילויות!** $\{1,2,3,4,5\} = \text{set}((1,3,4,5,5,2,1,1))$ — קריטי לפני jaccard.

Pandas — groupby

• **שתי עמודות:** `df.groupby(['a','b'])['c'].sum()` — **רשימה!** `['a']` ← שגיאה. איטרציה: `for key, g in df.groupby(...):` ; `g.shape` (שורות, עמודות). ברירת מחדל: ממין לפי מפתח, והמפתח הופך ל-`index`.

• **as_index=False** (נכון!): שומר את עמודת הקיבוץ כעמודה רגילה במקום index — נוח לפני `merge`: `df.groupby('class', as_index=False)['grade'].mean()`

• **apply עם lambda** (חוזר): יצירת עמודה מחושבת — `df['y'] = df['date'].apply(lambda d: int(d.split('/')[1]))` (חילוף חודש מ-DD/MM/YYYY).

Pandas — merge (תאר פלט בצורת dataframe!)

df1 (name, team)	df2 (team, est)	how = ...
Moshe · development Adam · research Emily · HR	development · 2008 research · 2013 finance · 2010	inner Adam, Moshe רק המשותפים: left est=NaN עץ Emily+ :df1 כל outer NaN(finance+) NaN(Emily+ :כל:

שאלת המשך הקבועה: מדדים על העמודה אחרי merge

`NaN`, 2013, 2008[:est עמודת 'left'how=
`count()` = 2 `sum()` = 4021.0
sum-ו מדלגים על NaN — 13 !

פעולות קבוצה (set) — 6 הופעות

• `A.intersection(B)` = חיתוך · `A.union(B)` = איחוד · גודל החיתוך חלקי גודל האיחוד = `jaccard` על קבוצות.

• **(set) מסיר כפילויות תחילה!** $\{1,2,3,4,5\} = \text{set}((1,3,4,5,5,2,1,1))$ (5 איברים, לא 8).

מתכון merge:

- `inner` = חיתוך המפתחות (רק ערכים שקיימים בשני הצדדים).
- `left` = כל שורות השמאלי; חסרים בימני ← `NaN`.
- `outer` = איחוד; חסרים משני הצדדים ← `NaN`.
- מדד על העמודה: `count` **מדלג על NaN** (סופר רק ערכים), `sum` **מדלג על NaN**. `mean = sum/count` (על הקיימים).

דפוס הזהב — "מעל הממוצע בקבוצה"

```
g = df.groupby('dept', as_index=False)['sal'].mean()
g.rename(columns={'sal':'avg'}, inplace=True)
m = df.merge(g, on='dept')
print(m[m['sal'] > m['avg']])
```

`rename` ← `groupby` (שלא יתגש) ← `merge` (מצימד ממוצע לכל שורה) ← `סיון` בוליאני. חוזר עם עובדים ועם תלמידים/כיתות.

קודים מוכרים (הפלט מאומת בהרצה)

קוד	מה עושה	פלט
<code>set(...)+count>1</code>	ערכים חוזרים בלבד	[1,2,5,9]
ראשוניים 19..2 (מסכה)	סכום	77
פלינדרום (בניית הפוך)	756 / 757	True / False
<code>reversed + zip</code>	צופן מראה a ↔ z	a → z, b → y
LCM (while)	lcm(7,6)	42
<code>len(set(s))/len(s)</code>	גיוון לקסיקלי	16/19
<code>sorted(key=d.get)</code>	תו שכיח	'e'


מתכון "מה מבצעת התוכנית (במשפט אחד)":

- להריץ בראש על הקלט הנתון ולרשום את הפלט.
- לנסח את הכוונה, לא את השורות: "סוכמת את הראשוניים בין 2 ל-20", "בודקת האם המספר פלינדרום" — משפט אחד ברמת מהות.

6 · רווחי סמך (CI) לתוחלת

$$CI = \bar{x} \pm Z \cdot s / \sqrt{n} \quad L = 2 \cdot Z \cdot s / \sqrt{n}$$

(L = האורך הכולל של הרווח — פעמיים המרווח)



מתכון [left, right] של X% מהשטח" (חזר +8 פעמים!):

- סימטרי: $z = Z(0.5 + X/2)$ ← $left = \mu - z \cdot \sigma$, $right = \mu + z \cdot \sigma$. דוגמה: $N(70,10)$, 80%: $z=1.28$ → [57.2, 82.8].
- לא-סימטרי (Y% משמאל, X% מימין): גבול שמאלי ב- $\mu - Z(0.5 - Y) \cdot \sigma$, ימני ב- $\mu + Z(0.5 + X) \cdot \sigma$. בהתאמה 50% עם $-\infty$.

מתכון חישוב CI (4 שלבים — להראות הכל!):

- אם נתונה שונות ← $s = \sqrt{\text{שונות}}$ (המלכודת מס' 1!)
 - Z לפי רמת ביטחון C: $Z((1+C)/2)$ — או ישר משורת "ביטחון" בטבלת עמוד 1. 99% ← 2.58 · 90% ← 1.65 · 85% ← 1.44
 - מרווח: $Z \cdot s / \sqrt{n}$
 - תשובה: [מרווח $\bar{x}$, מרווח $\bar{x}$]
- מחושב:** שונות 2.5, $\bar{x}=500.8$, $n=100$, ביטחון 99%: $s=1.58$ ← מרווח $0.41 = 1.58/10 \cdot 2.58$ ← [500.39, 501.21]

מתכון גודל מדגם (אורך נדרש L):

- $\sqrt{n} = 2 \cdot Z \cdot s / L$ ← מעלים בריבוע
- מעגלים תמיד למעלה!** (519 אריות · 1153 ל-679 IQ צמיגים)

מתכון הפוך (נתון L, מחפשים שונות):

- $s = L \cdot \sqrt{n} / (2Z)$
- מבקשים שונות? **להעלות בריבוע.** ($n=729$, $L=0.25$, ביטחון 95% ← $s^2 = 2.96 = 0.25 \cdot 27 / 3.92 = 1.72$)

מלכודות CI: ① שונות נתונה ← שורש לפני הצבה. ② "אורך/רוחב" = פעמיים המרווח. ③ התפלגות המקור אחידה/מוטת? **לא מפריע** — CLT מציל במדגם גדול. ④ תקן/דרישה מחוץ לרווח ← לא ניתן להצהיר עמידה בתקן.

פרשנות נכונה — נשאל שוב ושוב

- ✓ "בביטחון C, תוחלת האוכלוסייה נמצאת בטווח."
- ✗ "C אחוז מהפרטים בטווח." ✗ "פרט אקראי יפול בטווח בהסתברות C" — הרווח על הממוצע בלבד, והוא מצטמצם עם $1/\sqrt{n}$; פיזור הפרטים רחב בהרבה.

מה מצמצם את הרווח

n ↑ · רמת ביטחון ↓ (קטן Z) · שונות ↓ — וההפכים מרחיבים.

אל תבלבלו CI עם טווח נורמלי! CI לתוחלת = $\bar{x} \pm Z \cdot \sigma / \sqrt{n}$ (עם $\sqrt{n}$). טווח סימטרי של X% מהאוכלוסייה = $\mu \pm Z \cdot \sigma$ (בלי $\sqrt{n}$). שאלת [left,right] של 80% מהשטח" = הטווח, לא CI.

7 · פייתון — דפוסים ומלכודות

• **מפתח מילון חייב hashable:** `TypeError · tuple/str/int` ← `list` ← תקין.

• **tuple = immutable:** השמה `t[i]=x` ← `TypeError · list` — מותר.

• **פרמטרים לפונקציה:** `lst[i]= / lst.append(...)` משנים את המקור; `param = [...]` **מנתק** — המקור לא משתנה. מחרוזות immutable — לעולם לא משתנות דרך פרמטר.

• `s.replace("a", "X")` שקול ל- `"X".join(s.split("a"))`

• `count(x)>1` חוזרים = יחידאיים ← לקרוא את התנאי בעיון!

• **לזהות מה הקוד עושה — סימנים מנחים:** בניית מספר הפוך `( r = r*10 + num%10 )` ← פלינדרום/היפוך · `r%a==0 and r%b==0` עד `r==0` LCM: `d[c1]!=c2` עם `reversed` ← צופן/מיפוי · `set(list)` בתוך `comprehension` ← הסרת כפילויות · `key % len` ← **SyntaxError** ← `[x if cond for x in L]` ← תקין: `[x for x in L if cond]`

8 · גרסיה לינארית

$$MSE = (1/n) \cdot \sum (y - \hat{y})^2 \quad R^2 = 1 - SSE/SST$$


• R^2 = שונות מוסברת: $1 - \frac{\sum (y - \hat{y})^2}{\sum (y - \bar{y})^2}$. ההגדרה נשענת על ניבוי רציף – לא ישימה ללוגיסטית (שם R^2 -pseudo).

• **מקדמי גרסיה פשוטה:** $b_1 = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sum (x - \bar{x})^2}$, $b_0 = \bar{y} - b_1 \cdot \bar{x}$ ← כשאין קשר (רעש): $b_1=0$ ו- $b_0=0$ ← **ממוצע y בדיוק**.

• **loss חלופי – הכלל:** מעניש כל שגיאה (בלי קיזוז) + קטן=טוב.

חלופה ל-MSE	תקין?	למה
$ \Delta $ (MAE)	✓	חיובי, מעניש כל שגיאה
Δ^4	✓	זוגי, רגיש לחריגים
Δ^3	✗	סימנים מתקזזים
Δ^2	✗	מתגמל שגיאות ענק

• **R^2 adjusted:** עולה תמיד עם עוד משתנה (גם חסר תועלת). R^2 "מעניש" משתנים מיותרים – פער גדל בין השניים = מודל עמוס. הסרת משתנה לא-מובהק ← R^2 adjusted עשוי לעלות.



רעש: $b_1=0, b_0=\bar{y}$ ← חפוש חיתוך
 U ← פולינומי/piece-wise (חפוש נק' חיתוך שממזער MSE כולל של שני הקטעים)
 לינארי ✓ $b_1 > 0$

מתכון טבלת OLS (חזרה ב-6 מבחנים!):

- לכל משתנה להסתכל רק על $p < 0.05$: $P > |t|$ = מובהק – הסרתו **תוריד** R^2 . גדול = לא מובהק – הסרה לא משפיעה; R^2 adjusted אף עשוי לעלות.
- R^2 לעולם לא עולה מהסרת משתנה.
- "למי ההשפעה הגדולה ביותר?" בלי scaling – **לא ניתן לדעת!** (מקדם תלוי סקאלה). אחרי scaling – כן, לפי |מקדם|.
- במטריצת **מתאמים** (פירסון) – כן משווים תמיד: |ז| הגבוה מול y מנצח.
- CI של β_1 שכולל 0 (למשל [2.51, -3.11]) ← אין עדות לקשר לינארי.

Multi-collinearity

- מתאם חזק בין משתנים **בלתי תלויים** (0.84: $x_2 - x_4$ · שטח → חדרים).
- **פוגע:** פרשנות מקדמים, סימן הפוך, מובהקות מזויפת (ק גדול למרות קשר אמיתי). **לא פוגע:** R^2 , חיזוי, test.
- **זיהוי קל** – מטריצת מתאמים. פתרון: להסיר את בעל המתאם הנמוך יותר עם y. scaling / dummy – לא פותרים.
- **דוגמה (2025א):** $Y = 3.36 + 0.2 \cdot \text{size} - 0.52 \cdot \text{bedrooms}$. הצבה (3, 1500): $3.36 + 300 - 1.56 = 301.8$ ✓. "כל חדר מוריד 0.52" X – מקדם שלילי בגלל collinearity; המודל תקף לניבוי, R^2 גבוה.

מתכון "האם מתאים לגרסיה לינארית?" (מטבלת נתונים):

- לצייר/לדמיין את הנקודות. מגמה מונוטונית (רק עולה או רק יורד) ← מתאים, $b_1 \neq 0$.
- צורת U / הפוך-U (יורד ואז עולה) ← **לא מתאים** – קו ישר יפספס. (חשבון חשמל מול טמפ' = U קלאסי).
- אומדן "על מפת": $\Delta y / \Delta x \approx b_1$ מהקצוות · $b_0 \approx y$ ההתחלתי פחות $b_1 \cdot x$.

scaling · קידוד · חסרים · לוגיסטית

- scaling בגרסיה: **לא** משנה את טיב המודל; כן משנה מקדמים (גם scaling של y). לא הכרחי – בניגוד ל-KNN/KMeans/רשתות.
- נומינלי ← **dummy (one-hot)**. קידוד אזורים 1-5 ← כופה סדר ומרחק מלאכותיים X (כשל: מחיר גבוה באמצע הציר).
- ערכים חסרים בהתפלגות מוטה ← **חציון**.
- לוגיסטית: **sigmoid** $\sigma(z) = 1/(1+e^{-z})$ ← הסתברות; אימון **log loss** (לזהות במבחן!): $-\sum [y \cdot \log(\hat{y}) + (1-y) \cdot \log(1-\hat{y})]$ ← לא MSE.
- **למה לא R^2 רגיל בלוגיסטית?** R^2 מבוסס ריבועי סטיות של ניבוי רציף סביב ממוצע; כאן התוויות 0/1 והפלט הסתברות ← ההגדרה לא משקפת טיב סיווג. לכן R^2 -pseudo (McFadden), הערכה נוספת: accuracy, confusion, precision/recall, ROC/AUC.
- **loss 0-1** "עובד" (סופר טעויות) אבל גם – נותן עונש זהה לטעות ב-0.49 ולטעות ב-0.01; log loss מבחין ולכן עדיף לאימון.

9 · סיווג והערכה

איזה מודל לפי צורת הפיזור? נתונים שזורים / טבעת / לא-לינארי ← **KNN, NNR**, **MLP** ✓. גרסיה לוגיסטית ← גבול לינארי בלבד X. גרסיה לינארית ← לא מסווג כלל X. KMeans ← לא מונחה, לא מנבא מחלקות X.

	pred A	pred B	pred C
act A	50	10	10
act B	20	50	20
act C	5	5	50

עמודה אדומה = precision(A) = 50/70!
 שורה כחולה = recall(A) = 50/70
 accuracy = אלכסון/הכל = 150/220

אותו תא אלכסון (50), מכנים שונים: precision = עמודה (מה שחזיתי) · recall = שורה (מה שאמיתי)

מתכון confusion:

- סה"כ דוגמאות = סכום כל התאים (220).
- precision(X) = תא האלכסון של X חלקי **סכום עמודת** predicted X.
- recall(X) = אותו תא חלקי **סכום שורת** actual X.
- "כמה דוגמאות B יש" = סכום שורת (90) B.

• $P, R \in [0,1]$ · סכומם על מחלקות לא חייב $SR = 3 \cdot 1$ ייתכן (מסווג מושלם).
 $P+R \leq 2$ תמיד $P=1$ **לא גורר** $R=1$ (מסווג "שמרן").

- **accuracy לבדו לא מספיק:** מחלה של 1% – "תמיד בריא" נותן 99% ומחמיץ הכל (recall=0). שני מסווגים עם acc זהה – נעדיף את המכסה את כל המחלקות.
- **F1-score** – הממוצע ההרמוני של precision ו-recall: $F1 = 2 \cdot P \cdot R / (P+R)$. מאזן בין השניים **במספר יחיד**; גבוה רק כששניהם גבוהים (אם אחד נמוך – F1 נמוך). שימושי כשהמחלקות לא מאוזנות, במקום להסתכל על accuracy מטעה. טווח [0,1], 1 = מושלם.
- **ROC/AUC:** TPR מול FPR על פני כל הספים. $AUC \approx 1$ דירוג מושלם · 0.5 ניחוש · **שינוי סף לא משנה AUC**.

דוגמה מלאה (מהמטריצה למעלה, סה"כ 220):

precision(A)=50/75 · recall(A)=50/70 · precision(C)=50/80 · recall(C)=50/60
 accuracy=150/220 ≈ 0.68 · דוגמאות B בפועל = שורת B = 90.

שני מסווגים, אותו (5/10) accuracy: מסווג שלא חוזה C אף פעם (recall(C)=0) נחות מזה שמכסה את כל שלוש המחלקות – **נעדיף כיסוי מלא**. זו הסיבה accuracy לבד מטעה.

- חלופות פסולות: חלוקה בסכום (שליילים!) · ריבועים (הורס סדר: 3- מנצח את 1) · argmax קשיח (לא גזיר).
- **sigmoid**: טווח (0,1) — לא [1,1] (זה tanh)! בינארי בלבד; לא לרציף. softmax — כל מספר מחלקות (בבינארי שקולה ל-sigmoid).
- **CNN** — שיתוף משקלים: פרמטרים כמספר תאי הפילטר + זיהוי feature בכל מקום. LLM: טקסט רחוט ✓, אומן על שיחות ✓, רשת כמסווג token הבא ✓, אחזור עובדות מדויק X (היות!).

12 · אשכולות, PCA ו-Scaling

- **K-Means**: עזירה בהתכנסות (לא לפי גודל נתונים). רגיש לאתחול — ריצות שונות = תוצאות שונות; טיפול: n_init (בוחרים inertia מזערי) + KMeans++. קיים אתחול שמתכנס באיטרציה אחת. באגים בקוד: [0]shape · break · range(k) · previous=copy(current).
- **בחירת K**: לולאה + silhouette (מקסימום) או elbow על inertia $= \sum |x - c|^2$ — יורד תמיד, מחפשים את ה"שבירה".
- **rand index**: זוגות מוסכמים / $n(n-1)/2$. שיטה: לספור את הלא-מוסכמים. $0.8 = 8/10$ מול $[A,A,B,B,B]$ רק $(4,5), (3,5)$.
- **purity**: $\sum$ (רוב בכל אשכול) $12/(3+4+2) = 0.75$. חסם 1: טריוויאלי ב-K.
- **silhouette**: $s = (b-a)/\max(a,b)$, ללא תיוגים — הפרדה גיאומטרית. שתי חלוקות נכונות זהות-rand יכולות לקבל s שונה. precision/recall — לא לאשכולות!
- **אלגוריתם סף-דמיון (תרגיל 4, נבחן פעמיים ב-2025)**: MS גבוה — אשכולות קטנים ורבים; NUM=n ייתכן: $MS1 > MS2$ — בוודאות NUM1 > NUM2 X (מגמה כן, ודאות לא). יתרונות מול KMeans: לא צריך K, סובלני לחריגים.
- **DBSCAN**: eps — מיוזג, רעשו. הכל רעש — eps או min_samples; אשכול ענק — ההפך. אין K.
- **PCA**: מתאם מושלם — $PC1=100\%, PC2=0\%$. מתאם חזק — כיוון הסכום מסביר את הרוב.
- **StandardScaler**: $\sigma/(x-\mu)$ — ממוצע $\sigma=1$, לא חסום; פר-עמודה ($axis=0$). מחושב: $[1,3,5,7,9]$ — $[-1.41, -0.71, 0, 0.71, 1.41]$. MinMax: $(\max-\min)/(x-\min)$ — $[0,1]$ — $[-5,10,15,7]$ — $[0, 0.75, 1, 0.6]$. "Standard מעביר ל-[0,1]"!
- **מונחית** = יש תוויות (מחירים, ספרות); **לא מונחית** = מבנה בלי תוויות (פילוח, קיבוץ). KMeans אינו מסווג!

סיכום: פונקציית אימון והערכה לכל מודל

מודל	אימון (loss)	scaling חשוב?	לא-לינארי?
רגרסיה לינארית	MSE	לא (רק לפרשנות)	לא
רגרסיה לוגיסטית	log loss	כן (ב-GD)	לא (גבול לינארי)
KNN / NNR	אין אימון!	כן (מרחקים)	כן ✓
רשת (MLP)	cross-entropy	כן	כן ✓
KMeans	inertia (לא מונחה)	כן	—


מלכודות-על — לבדוק לפני הגשה: ① שונות נתונה — שורש. ② אורך CI = $2 \times n$ מרווח; n מעוגל למעלה. ③ ת"ז/מיקוד = קטגורי. K ④. sigmoid $\in (0,1)$. אי-זוגי רק בבינארי. ⑤ "ייתכן" כמעט תמיד נכון, "בוודאות" כמעט תמיד לא. ⑦ "הכי משפיע" בלי scaling — לא ניתן לדעת. ⑧ $P(x>a)$ — להפוך את ערך הטבלה. ⑨ KMeans אינו מסווג; ל-KNN אין אימון. ⑩ merge: count/sum מדלגים על NaN. לא עולה בהסרה. ⑪ collinearity לא פוגע בחיזוי — רק בפרשנות. על R^2 ⑫.

מבנה המבחן (לפי 11 מועדים): 14- שאלות · שתיים וחצי · "מה יודפס + מה מבצעת (במשפט אחד)" · "יכול/לא נכון והסבירו" · "סמנו את כל הנכונות" · חישוב מלא עם דרך · שאלת פיזור · שאלת OLS. **טכניקה:** נכון/לא-נכון בלי נימוק = חצי נקודות; בחישובים להראות הצבה מלאה — נקודות חלקיות על דרך; "מה מבצעת" — משפט אחד ברמת כוונה.

כל החישובים אומתו בהרצת קוד · בהצלחה!

10 · מרחקים ו-KNN

מנהטן	$\sum \Delta_i $	אוקלידי	$\sqrt{\sum \Delta_i^2}$
hamming	חלק המקומות השונים, מקום מול מקום — תמורה מלאה = 1.0. מחושב: $1/3 = ([1,1,0],[1,0,0])$		
jaccard (sets)	גודל החיתוך חלקי גודל האיחוד = 1 זהים. מחושב: $0.5 = 4/8 = \{1,2,4,5,6,7,8\}$		
scipy.jaccard	אי-דמיון (0 זהים): אי-הסכמה רק במקומות שלפחות אחד $\neq 0$. מחושב: $2/3 = ([1,1,1,0],[1,0,0,0])$		




שאלת פיזור — התבנית הקבועה:
 K=1 טועה (שכן בודד מטעה)
 K=3 מתקן (רוב מקומי)
 "קיים R עם דיוק מלא" — לרוב נכון
 מתאים ל-MLP ✓ · KMeans X · לינארי X

מתכון KNN מחושב (מנהטן, K=3):
 אל $W=4 \cdot (4,4)B=4(1,5) \cdot 3=B(2,5) \cdot 1=W=2 \cdot (3,2)W(1,1)$ שלושה קרובים:
 $W, (1,1)W, (2,5)B(3,2)$ רוב White. (עם K=1 היה יוצא אחרת — לשים לב ל-K!)

- **K**: גדול $\neq$ טוב! $|K|=|train|$ — תמיד מחלקת הרוב. K קטן — רגיש לרעש. בוחרים ב-K validation. אי-זוגי מונע תיקו רק בבינארי (2-2-1 בחמש מחלקות!).
- **scaling קריטי**; אבל הכפלה אחידה של כל הצירים — לא משנה כלום (סדר שכנים נשמר). StandardScaler שונה-לכל-feature — כן משנה. אחרי Standard מרחק לא חסום (מעל N אפשרי); אחרי MinMax — חסום ב-NV.
- עמיד לחריגים: ל-KNN אין שלב אימון — CE loss לא רלוונטי (בחירת K = כיוונון, לא אימון).
- **NNR**: רדיוס ענק — מחלקת רוב (לא "יותר-מדויק"). features זהים בין datasets — "ייתכן $R1=R2$ " ✓, "בוודאות" X. אחרי scaling הרדיוסים ישתנו.
- **train/val/test**: אימון / כיוונון (K, R) / הערכה סופית נקייה.
- **CE**: $CE = -\log_{10}(p)$, $p =$ הסתברות המחלקה האמיתית. $CE > 1 \Rightarrow p < 0.1$. דוגמה: אמת A, פלט $[0.05, 0.90, 0.05]$ — $1.30 = \log(0.05)$. לא חסום למעלה.

11 · רשתות נוירונים ו-Gradient Descent



מתכון צעד GD: ① נגזרת בנקודה: $f'(x)$ ② צעד $\alpha \cdot f'(x)$ ③ צעד $x - x$. מקסימום? מחליפים ל-+. מחושב: $x \leftarrow f=3, x=0, \alpha=0.1, y=x^2+3x, -0.3$. השלמת קוד: $slope=derivative(x)$ (לא הפונקציה!) — $step=lr \cdot slope$ — $x=x-step$.

α	1 (על 2, מ-5)	0.5	0.1	0.1-	0	גדול מאוד
קורה	זגזוג ± 5 נצחי	0 בצעד אחד	ירידה הדרגתית	מטפס ומתרחק	לא זז	התבדרות

- תלולה (20×2) מסוכנת ממתונה (2×2) עם אותו scaling — α "מעגל" את נוף ה-loss ועוזר לאימון.
- **GD מול פתרון אנליטי**: יתרון — עובד כשאין פתרון ל- $f=0$; חיסרון — מקורב, עלול להיתקע בלוקאלי.
- **Perceptron**: רק הפרדה לינארית — נכשל ב-XOR; מדרגה לא גזירה. הפתרון: MLP + אקטיביציות לא-לינאריות.

sigmoid · softmax

$$\text{softmax}(z_i) = e^{z_i} / \sum e^{z_j} \cdot \sigma(z) = 1/(1+e^{-z})$$

• softmax: כולם ב-(0,1), סכום 1, תמיד חיובי (גם לקלט שלילי!), משמר סדר. מחושב: $e^{-1}=0.368, e^{1.5}=4.48, e^7=1096.6$ סכום 1101.5 — $[0.0003, 0.0041, 0.9956]$